

Enrichir pendant l'import : ce que ca aurait change

Analyse de notre base reelle (fevrier - octobre 2026, lecture seule) et scenario retroactif : que se serait-il passe si un pipeline de validation, de deduplication et d'enrichissement avait existe des le premier import ?

136 835

recherches si on enrichit
tout a l'import

24 851

recherches vraiment
necessaires (-82 %)

17 116

au demarrage si on cible
les missions actives (-87 %)

Verdict


- **Ne pas enrichir toute la base a l'import.** 56 % de nos contacts (39 742) n'ont jamais ete appeles : les enrichir a l'arrivee, c'est payer pour des donnees qui dorment.
- **Le gros gain est gratuit.** Normaliser les numeros, dedupliquer et appliquer les exclusions avant d'appeler : 7 776 appels (11,4 %) ont ete passes sur des doublons d'entreprise, et 5 676 appels (8,3 %) ont fini en numero faux, doublon ou hors cible.
- **L'enrichissement payant doit etre cible et declenche par un besoin :** 11 975 entreprises et 12 876 contacts n'ont *aucun* numero joignable. Le reste est deja complet ou en double.
- **Fourchette d'impact sur 8 mois :** 1 982 a 10 525 appels evites (2,9 % a 15,4 %), soit 170 a 902 heures de SDR, environ 12 a 62 RDV de plus au taux de conversion actuel. Les hypotheses sont detaillees page 4 : ce sont des estimations, pas des mesures.

Ce que l'article Cognism apporte (et n'apporte pas)

L'article est un contenu marketing de Cognism (publie le 23 juin 2026). Il decrit le principe - on envoie un email ou un domaine, l'API renvoie des champs completes en quelques secondes - mais il ne donne **aucun prix, aucun conseil de reduction de cout, aucun taux de match ni de limite d'API**. Il ne compare pas non plus l'enrichissement a l'import, en lot ou en temps reel. Les recommandations de ce document viennent donc de nos donnees, pas de l'article. Seul chiffre cite : 10 % du chiffre d'affaires perdu a cause de mauvaises donnees CRM (attribue a Gartner), non verifie ici.


1. Etat de notre base

65 591 entreprises, 71 244 contacts, 168 listes (165 imports CSV) dans 37 missions dont 33 actives, 68 336 appels passes. Les imports arrivent par vagues.



Entreprises importees par mois

Qualite des donnees contacts




Sur 20 564 contacts sans numero, 10 571 ont au moins le standard de l'entreprise ; 9 993 n'ont rien du tout.

Doublons (le poste qui coute le plus cher)

Regle de doublon	Lignes en trop	Part de la base
Meme nom, meme mission	12 624	19,2 %
Meme site web, meme mission	8 553	23,3 % des fiches avec site
Meme nom, toutes missions confondues	18 874	28,8 %
Contacts : meme email	12 777	17,9 %
Contacts : meme numero valide	9 283	13,0 %

La deduplication actuelle (lib/import/dedup.ts) ne regarde que le **nom d'entreprise**, dans la liste cible ou la mission. Elle ne voit ni le domaine web, ni l'email, ni le numero, et ignore les autres clients. 3 730 groupes de doublons ont ete travailles plus d'une fois.

2. Ce que les donnees mauvaises nous ont coute en appels



Echelle tronquee : 'Pas de reponse' = 45 146 appels (66 %). Il faut 169 appels pour un RDV (0,59 %).

Poste de perte	Appels	Part	Lecon pour l'import
Appels sur lignes en double (meme nom, meme mission)	7 776	11,4 %	Dedupliquer par domaine / email / numero avant de charger la liste
Faux numero / numero KO / mauvais contact	2 863	4,2 %	Valider le format, puis verifier la ligne avant la file d'appel
Hors cible	2 063	3,0 %	Completer secteur / taille et filtrer avec l'ICP de la mission
Doublon signale par le SDR (deja inclus plus haut)	750	1,1 %	Plancher mesure : ce que les SDR ont eux-memes vu
Contacts rappelés 3 fois ou + sans jamais repondre	14 218	20,8 %	3 457 contacts ; 7 304 appels apres le 2e echec : declencher la recherche d'une ligne directe

Ce que notre enrichissement actuel donne

Aujourd'hui l'enrichissement n'existe qu'apres coup, entreprise par entreprise, depuis la fiche SDR : Mapbox puis Google Places pour le standard, recherche web IA, et un scraper de site. Resultat mesure en base :

- 470 recherches de telephone au total pour 65 591 entreprises (moins de 1 % de couverture), dont 53 ont trouve un numero (**11 %**) et 42 ont ete appliques.
- 644 recherches IA, dont 57 sans resultat et 10 servies par le cache.
- Les sources utilisees (Mapbox, Google Places) trouvent le standard d'une entreprise, rarement une ligne directe : c'est le besoin d'un fournisseur de donnees B2B, pas de ces outils.
- Le module Apollo (lib/listing) suit deja les credits et le cache : c'est la base du garde-fou de budget a reutiliser.

3. Scenario retroactif : un import intelligent des le debut

Trois facons de traiter la meme base, en nombre de recherches payantes (une recherche = un contact ou une entreprise envoy   a un fournisseur) :

Strategie	Entreprises	Contacts	Total	vs. tout enrichir
A. Tout enrichir a l'import	65 591	71 244	136 835	-
B. Import intelligent : seulement ce qui manque, hors doublons et exclusions	11 975	12 876	24 851	-82 %
C. B + seulement les missions actives, jamais travaille	8 926	8 190	17 116	-87 %

B : entreprise sans aucun numero joignable (ni le sien ni celui d'un contact), sans doublon, non exclue ; contact sans numero valide ni standard d'entreprise. C : en plus, uniquement les listes non archivees des missions actives et les fiches jamais travaillees ; le reste est enrichi a la demande.

Cout : a quel prix par recherche cela vaut-il le coup ?

Nous n'avons aucun tarif fournisseur (l'article n'en donne pas). Voici donc le cout pour trois prix illustratifs, **qui ne sont pas des devis**, puis le prix maximal auquel la strategie B se rembourse uniquement par les appels evites.

Prix par recherche (illustratif)	A. tout enrichir	B. intelligent	C. cible
0,10 EUR	13 684 EUR	2 485 EUR	1 712 EUR
0,30 EUR	41 050 EUR	7 455 EUR	5 135 EUR
0,60 EUR	82 101 EUR	14 911 EUR	10 270 EUR

Gain operationnel (appels evites)

Source	Hypothese basse	Hypothese haute
Doublons d'entreprise	750 (seulement ceux vus par les SDR)	7 776 (toutes les lignes en double)
Faux numeros	716 (25 % detectes)	1 718 (60 % detectes)
Hors cible	516 (25 %)	1 032 (50 %)
Appels evites	1 982 (2,9 %)	10 525 (15,4 %)
Heures de SDR	170 h	902 h
Valeur a 25 EUR/h (hypothese)	4 246 EUR	22 554 EUR
RDV supplementaires au taux actuel	12	62

Seuil de rentabilite. Avec la strategie B (24 851 recherches), les seuls appels evites remboursent un prix jusqu'a **0.17 EUR** par recherche (hypothese basse) ou **0.91 EUR** (haute) ; avec C (17 116), 0.25 a 1.32 EUR. Au-dela, il reste le gain non chiffre ici : rendre appelables les 9 993 contacts sans aucune ligne et trouver des lignes directes pour les 3 457 contacts qui ne repondent jamais.

Hypotheses : 5.1 min par appel (objectif 70 appels pour 6 h effectives, a ajuster) ; les durees d'appel ne sont renseignees que pour 129 appels, donc impossible de mesurer le temps reel. Les taux de detection (25-60 %) sont des hypotheses, pas des mesures. Le taux de RDV moyen (0,59 %) est applique tel quel aux appels liberes.

4. Comment l'integrer a l'import

Principe : payer le plus tard possible, et seulement apres avoir fait tout ce qui est gratuit. L'import actuel (app/api/lists/import/route.ts, traitement par lots de 1 000) garde sa rapidite ; l'enrichissement payant part en file d'attente.

Etape	Ou	Cout	Effet attendu
1. Normaliser et valider les numeros (libphonenumber, deja en dependance ; regle mobile +33 6/7)	import, synchrone	gratuit	Marque les 5 514 numeros invalides ; evite de les envoyer a un fournisseur
2. Dedupliquer sur domaine web, email et numero normalise, en plus du nom ; etendre a toute la base du client	lib/import/dedup.ts	gratuit	Jusqu'a 12 624 entreprises et 12 777 contacts en moins
3. Appliquer les exclusions ("ne plus contacter") avant toute recherche	ExclusionService, deja appele a l'import	gratuit	2 073 contacts et 504 entreprises exclus jamais envoyes
4. Reutiliser le cache d'enrichissement (cle : domaine / email / numero, duree 90 a 180 jours), partage entre clients	PhoneEnrichmentLookup et CompanyEnrichmentLookup ont deja queryHash + expiresAt	gratuit	12 579 domaines deja vus ailleurs dans la base
5. Decider quoi enrichir : champ manquant ET fiche destinee a la file d'appel ET mission active ET budget restant	nouvelle politique par mission, plafond de credits comme lib/listing/apollo-credits.ts	payant	De 136 835 a 17 116 recherches
6. Enrichir en tache de fond (cascade du moins cher au plus cher, paiement au resultat si le fournisseur l'accepte)	worker BullMQ (workers/enrichment.ts), ecriture en smart_merge : ne remplit que les champs vides	payant	Import rapide ; les donnees SDR modifiees ne sont jamais ecrasees
7. Declencheurs apres import : 2 echecs 'pas de reponse' -> chercher une ligne directe ; faux numero -> nouvelle recherche ; doublon -> fusion	ActionService	payant, cible	3 457 recherches au lieu de 14 218 appels repetes

Choix du fournisseur

- Ne pas s'enfermer : une interface *EnrichmentProvider* (Cognism, Apollo, un autre) derriere la cascade actuelle Mapbox, Google, IA.
- Comparer les offres sur le **cout par recherche reussie**, le taux de match sur un echantillon de nos fiches (par exemple 500 contacts sans numero) et la fraicheur des numeros mobiles, pas sur le prix par credit affiche.
- A verifier avec le fournisseur : conformite RGPD pour la prospection B2B par telephone en France, listes d'opposition, et conditions de reutilisation des donnees mises en cache.
- Pilote conseille : brancher l'etape 5 en mode 'simulation' d'abord (comme /api/lists/import/simulate) pour voir combien de recherches un import declencherait avant de depenser.

Limites de cette analyse

- Les doublons 'meme nom, meme mission' sont une borne haute : deux agences portant le meme nom seraient comptees comme doublon. Le recoupement par domaine web (8 553 lignes en trop) et les 750 appels marques DOUBLON par les SDR donnent des repères plus surs.
- Un appel sans reponse n'est pas toujours un mauvais numero : le gain sur les 66 % de 'pas de reponse' ne peut pas etre estime sans test.
- Aucun taux de match fournisseur n'est connu : tous les gains lies a la completion de numeros restent a mesurer par un pilote.
- Donnees lues en lecture seule sur la base Supabase ; periode du 1er fevrier au 8 octobre 2026.